

Структурное прореживание моделей глубокого обучения на основе суррогатных моделей

М. О. Иванов

`ivanov.mo@phystech.edu`

Москва, Московский физико-технический институт

2026

Цель исследования

Цель

Предложить метод структурного прореживания нейросетей.

Проблема



Существующие методы работают послойно. Учёт взаимосвязей между слоями модели является вычислительно сложной задачей.

Метод решения

Предлагаемый метод основан на построении суррогатной графовой модели, повторяющей структуру исходной нейросети.

Схема предлагаемого решения

Упрощённая схема residual connection и соответствующей суррогатной графовой модели. Каждому ребру сопоставляется γ , по множеству которых граф оптимизируется.



Постановка задачи

- ▶ Архитектура модели представляет собой ориентированный ациклический граф $G = (V, E)$. Каждая вершина $v_i \in V$ соответствует слою нейронной сети, и каждое ребро $e_{ij} \in E$ представляет поток данных из выхода слоя v_i до входа v_j .
- ▶ В данной формулировке удаление вершины означает удаление соответствующего слоя из сети, тогда как удаление ребра к устранению зависимости передачи данных между слоями (например, в случае residual connection).
- ▶ Задана выборка $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}}$. Задана функция потерь $\mathcal{L}$. Пусть $\mathbf{w}$ – параметры модели до прунинга, а $\mathbf{w}'$ – параметры модели после. Задача оптимизации

$$\min_{\mathbf{w}' \in \mathbb{R}^k} |\mathcal{L}(\mathcal{D} \mid \mathbf{w}') - \mathcal{L}(\mathcal{D} \mid \mathbf{w})|.$$

Предлагаемый метод

- ▶ Пусть задано $\gamma_{ij} \in [0, 1]$ для каждого ребра $e_{ij} \in E$. Также для графа G задана маска рёбер $\mathbf{M} \in \mathbb{Z}_2^{|E|}$:

$$(\mathbf{M})_{ij} = 1 \quad \Leftrightarrow \quad \gamma_{ij} = 0.$$

- ▶ Дополнительно накладываем следующее ограничение на исходящие ребра каждой вершины:


$$\sum_{j: e_{ij} \in E} \gamma_{ij} = 1$$

- ▶ Тогда оптимизационная задача:

$$\begin{aligned} \gamma = \arg \min_{\gamma \in [0,1]^{|E|}} & \quad \left(\mathbf{E}_{\mathbf{M}} \|G(\gamma, \mathbf{M}) - \mathcal{L}(\mathbf{M})\|_2^2 \right) \\ \text{s.t.} & \quad \sum_{j: e_{ij} \in E} \gamma_{ij} = 1. \end{aligned}$$

Постановка эксперимента

- ▶ Цель – сравнение качества базовых суррогатных моделей для предложенного метода.
- ▶ В сравнении участвуют следующие базовые методы:
 - ▶ **(Graph)**: Предложенный метод,
 - ▶ **(FCN)**: Простая нейросеть,
 - ▶ **(Linear)**: Линейная регрессия,
 - ▶ **(L1)**: Метод, основанный на измерении величин параметров,
 - ▶ **(Taylor)**: Метод, использующий приближение Тейлора до 1-го и 2-го порядков.



В эксперименте проводилась оптимизация суррогатных моделей, построенных на основе семплированных графов из $\text{ReLU}(\text{Linear}(x))$.

Результаты эксперимента

- ▶ Рассматриваются задачи классификации изображений из датасета MNIST.
- ▶ Приводятся значения коэффициентов корреляции Кендалла между истинными и прогнозируемыми значениями ошибок.

Model	10–15 edges	20–40 edges	50–100 edges	more than 100 edges
Graph	0.253 ± 0.202	0.242 ± 0.146	0.282 ± 0.105	0.329 ± 0.045
FCN	-0.011 ± 0.151	-0.042 ± 0.128	-0.020 ± 0.061	-0.036 ± 0.066
Linear	0.039 ± 0.135	0.137 ± 0.083	0.167 ± 0.061	0.199 ± 0.032
L1	0.401 ± 0.057	0.353 ± 0.049	0.259 ± 0.041	0.192 ± 0.057
Taylor	0.094 ± 0.182	-0.033 ± 0.055	-0.090 ± 0.051	-0.136 ± 0.030

Из таблицы видно, что предложенный метод демонстрирует высокую эффективность при решении предложенной задачи.

Результаты эксперимента




График истинных и прогнозируемых значений ошибок для сравнения методов.
Используется модель с 10–15 рёбрами.

Заключение

- ▶ Рассмотрена задача структурного прореживания нейросетей.
- ▶ Предложен метод структурного прореживания нейросетей на основе суррогатных моделей.
- ▶ Эксперименты показали, что предложенный метод превосходит суррогатные модели, которые не используют информацию о вычислительном графе.
- ▶ Планируется расширить и обобщить этот метод для прореживания по каналам (например, по фильтрам в свёрточных нейросетях).
- ▶ Планируется подача в рецензируемый журнал.