

Структурное прореживание моделей глубокого обучения на основе суррогатных моделей

Иванов М. О.

Научный руководитель: к.ф.-м.н. Бахтеев О. Ю.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 01.03.02 Прикладная математика и информатика

24 июня 2026

Структурное прореживание моделей глубокого обучения

Цель

Предложить эффективный метод структурного прореживания нейросетей.

Проблема

Существующие методы работают послойно. Учёт взаимосвязей между слоями модели является вычислительно сложной задачей.


Метод решения

Предлагаемый метод основан на построении суррогатной графовой модели, повторяющей структуру исходной нейросети.

Схема предлагаемого решения

На основе вычислительного графа нейросети строится суррогатная графовая модель, оптимизируемая таким образом, чтобы аппроксимировать функцию ошибки.

Суррогатная модель является критерием при процессе прореживания.



Задача структурного прореживания

Архитектура модели f представляет собой ориентированный ациклический граф $G = (V, E)$. Каждая вершина $v_i \in V$ соответствует слою нейронной сети, и каждое ребро $e_{ij} \in E$ представляет поток данных из выхода слоя v_i до входа v_j .

В данной формулировке удаление вершины означает удаление соответствующего слоя из сети, тогда как удаление ребра — к устранению зависимости передачи данных между слоями (например, в случае residual connection).

Пусть задана выборка $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}}$. Задана функция ошибки S . Пусть $\mathbf{w}$ — параметры модели до прореживания, а $\mathbf{w}'$ — параметры модели после. Кроме того, определим маску рёбер $\mathbf{M} \in \mathbb{Z}_2^{|E|}$, показывающую, является ли ребро удалённым. Тогда задача оптимизации структурного прореживания:

$$\min_{\mathbf{w}' \in \mathbb{R}^k} |S(\mathbf{w}', \mathbf{M} \mid \mathcal{D}, f) - S(\mathbf{w}, \mathbf{M} \mid \mathcal{D}, f)|.$$

Суррогатная графовая модель

Пусть задано $\gamma_{ij} \in [0, 1]$ для каждого ребра $e_{ij} \in E$. Также для графа G задана маска рёбер $\mathbf{M} \in \mathbb{Z}_2^{|E|}$:

$$\mathbf{M}_{ij} = 0 \quad \Leftrightarrow \quad \gamma_{ij} = 0.$$

Lemma

Графовая модель $G(\gamma, \mathbf{M})$ может быть представлена в виде

$$G(\gamma, \mathbf{M})[\mathbf{x}] = \mathbf{x} \cdot \sum_{p \in P} \prod_{(i,j) \in p} (\gamma_{ij} \cdot \mathbf{M}_{ij}),$$

где P — множество всех путей в графе.

Добавляя ограничение на веса рёбер, получаем оптимизационную задачу:

$$\begin{aligned} \gamma = \arg \min_{\gamma \in [0,1]^{|E|}} \quad & \mathbb{E}_{\mathbf{M}} \|G(\gamma, \mathbf{M}) - S(\mathbf{w}, \mathbf{M} \mid \mathfrak{D}, f)\|_2^2 \\ \text{s.t.} \quad & \sum_{j: e_{ij} \in E} \gamma_{ij} = 1. \end{aligned}$$

Теорема о локальной линейной аппроксимации функции ошибки графовой суррогатной моделью

Theorem (Ivanov, 2026)

Пусть функция ошибки S нормирована таким образом, что $S \in [0, 1]$. Для любой фиксированной вершины $i \in V$ пусть $E_i = \{(i, j) \in E\}$ обозначает множество исходящих из неё ребер, а $\mathbf{M}_i = \{\mathbf{M}_{ij} \mid (i, j) \in E_i\}$ — соответствующее подмножество масок, при этом все остальные маски рёбер в графе зафиксированы и равны 1.

Тогда функция ошибки S может быть локально аппроксимирована графовой суррогатной моделью следующим образом:


$$S(\mathbf{w}, \mathbf{M}_i \mid \mathfrak{D}, f) = C + \sum_{(i,j) \in E_i} \gamma_{ij} \mathbf{M}_{ij} + o(\|\mathbf{M}_i - \mathbf{1}\|),$$

где C — константа, а компоненты вектора коэффициентов определяются как:

$$\gamma_{ij} = \frac{\partial S}{\partial \mathbf{M}_{ij}}.$$

Вычислительный эксперимент

Рассматривается задача классификации изображений из датасета MNIST.



В эксперименте проводилась оптимизация суррогатных моделей, построенных на основе семплированных графов из нод $\text{ReLU}(\text{Linear}(\mathbf{x}))$.

В сравнении участвуют следующие базовые методы:

(Graph): предложенный метод,

(FCN): простая нейросеть,

(Linear): линейная регрессия,

(L1): метод, основанный на измерении величин параметров,

(Taylor): метод, использующий приближение Тейлора до 1-го и 2-го порядков.

Процент пересечения топ-5% моделей

Приводится процент пересечения топ-5% моделей, ранжированных в соответствии с истинной функцией ошибки, и моделей, ранжированных в соответствии с прогнозом суррогатной модели.

Model	10–15 edges	20–40 edges	50–100 edges	> 100 edges
Graph	62.0%	64.5%	69.3%	58.3%
FCN	2%	15.2%	5.2%	6.8%
Linear	18.8%	9.6%	27.2%	15.2%
L1	0.0%	1.6%	6.8%	6.8%
Taylor	8.0%	10.8%	29.6%	24.4%

Из таблицы видно, что предложенный метод демонстрирует высокую эффективность при решении предложенной задачи.

Прогноз функции ошибки против истинных значений




График истинных и прогнозируемых значений ошибок для сравнения методов. Используется модель с 10–15 рёбрами.

Выносятся на защиту

Достигнутые результаты

- 1) Доказана теорема о локальном поведении графовой суррогатной модели.
- 2) Проведены эксперименты, показавшие, что предложенный метод превосходит суррогатные модели, которые не используют информацию о вычислительном графе.
- 3) Планируется расширить и обобщить этот метод для прореживания по каналам (например, по фильтрам в свёрточных нейросетях).

Доклады по теме работы

- 1) Работа представлена на Всероссийской научной конференции МФТИ 2026.
- 2) Статья подготовлена к публикации, планируется подача в рецензируемый журнал.