

Структурное прореживание моделей глубокого обучения на основе суррогатных моделей

Иванов М. О.

Научный руководитель: к.ф.-м.н. Бахтеев О. Ю.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 01.03.02 Прикладная математика и информатика

13 июня 2026

Структурное прореживание моделей глубокого обучения

Цель

Предложить метод структурного прореживания нейросетей.

Проблема


Существующие методы работают послойно. Учёт взаимосвязей между слоями модели является вычислительно сложной задачей.

Метод решения

Предлагаемый метод основан на построении суррогатной графовой модели, повторяющей структуру исходной нейросети.

Схема предлагаемого решения

Упрощённая схема residual connection и соответствующей суррогатной графовой модели. Каждому ребру сопоставляется γ , по множеству которых граф оптимизируется.



Постановка задачи

- ▶ Архитектура модели представляет собой ориентированный ациклический граф $G = (V, E)$. Каждая вершина $v_i \in V$ соответствует слою нейронной сети, и каждое ребро $e_{ij} \in E$ представляет поток данных из выхода слоя v_i до входа v_j .
- ▶ В данной формулировке удаление вершины означает удаление соответствующего слоя из сети, тогда как удаление ребра к устранению зависимости передачи данных между слоями (например, в случае residual connection).
- ▶ Задана выборка $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}}$. Задана функция потерь $\mathcal{L}$. Пусть w – параметры модели до прунинга, а w' – параметры модели после. Задача оптимизации

$$\min_{w' \in \mathbb{R}^k} |\mathcal{L}(\mathcal{D} \mid w') - \mathcal{L}(\mathcal{D} \mid w)|.$$

Предлагаемый метод

- ▶ Пусть задано $\gamma_{ij} \in [0, 1]$ для каждого ребра $e_{ij} \in E$. Также для графа G задана маска рёбер $\mathbf{M} \in \mathbb{Z}_2^{|E|}$:

$$\mathbf{M}_{ij} = 0 \quad \Leftrightarrow \quad \gamma_{ij} = 0.$$

- ▶ Дополнительно накладываем следующее ограничение на исходящие ребра каждой вершины:

$$\sum_{j: e_{ij} \in E} \gamma_{ij} = 1$$

- ▶ Тогда оптимизационная задача:

$$\begin{aligned} \gamma = \arg \min_{\gamma \in [0,1]^{|E|}} \quad & \mathbb{E}_{\mathbf{M}} \|G(\gamma, \mathbf{M}) - S(\mathbf{w} \mid \mathfrak{D}, f)\|_2^2 \\ \text{s.t.} \quad & \sum_{j: e_{ij} \in E} \gamma_{ij} = 1. \end{aligned}$$

Предлагаемый метод

Theorem

Теорема Пусть задано значение $\mathbf{M} = \mathbf{1}$, соответствующее модели со всеми рёбрами, то есть


$$\forall (i, j) \in E : \mathbf{M}_{ij} = 1.$$

Тогда в окрестности $\mathbf{M} = \mathbf{1}$ функция ошибки S аппроксимируется формулой, соответствующей графу:

$$\begin{aligned} S(\mathbf{M}) = & \sum_{(i,j) \in E} \left. \frac{\partial G}{\partial \mathbf{M}_{ij}} \right|_{\mathbf{M}=\mathbf{1}} (\mathbf{M}_{ij} - 1) \\ & + \frac{1}{2} \sum_{(i,j) \in E} \sum_{(k,l) \in E} \left. \frac{\partial^2 G}{\partial \mathbf{M}_{ij} \partial \mathbf{M}_{kl}} \right|_{\mathbf{M}=\mathbf{1}} (\mathbf{M}_{ij} - 1)(\mathbf{M}_{kl} - 1) \\ & + o(\|\mathbf{M} - \mathbf{1}\|^2). \end{aligned}$$

Вычислительный эксперимент

- ▶ Рассматриваются задачи классификации изображений из датасета MNIST.
- ▶ В сравнении участвуют следующие базовые методы:
 - ▶ **(Graph)**: Предложенный метод,
 - ▶ **(FCN)**: Простая нейросеть,
 - ▶ **(Linear)**: Линейная регрессия,
 - ▶ **(L1)**: Метод, основанный на измерении величин параметров,
 - ▶ **(Taylor)**: Метод, использующий приближение Тейлора до 1-го и 2-го порядков.



В эксперименте проводилась оптимизация суррогатных моделей, построенных на основе семплированных графов из нод $\text{ReLU}(\text{Linear}(x))$.

Вычислительный эксперимент

Приводятся процент совпадений между топ-5% моделей, ранжированных в соответствии с истинной функцией ошибки, и моделями, ранжированными в соответствии с прогнозом суррогатной модели.

Model	10–15 edges	20–40 edges	50–100 edges	> 100 edges
Graph	62.0%	64.5%	69.3%	58.3%
FCN	2%	15.2%	5.2%	6.8%
Linear	18.8%	9.6%	27.2%	15.2%
L1	0.0%	1.6%	6.8%	6.8%
Taylor	8.0%	10.8%	29.6%	24.4%

Из таблицы видно, что предложенный метод демонстрирует высокую эффективность при решении предложенной задачи.

Вычислительный эксперимент




График истинных и прогнозируемых значений ошибок для сравнения методов. Используется модель с 10–15 рёбрами.

Выносятся на защиту

- 1) Доказана теорема о локальном поведении графовой суррогатной модели.
- 2) Проведены эксперименты, показавшие, что предложенный метод превосходит суррогатные модели, которые не используют информацию о вычислительном графе.
- 3) Планируется расширить и обобщить этот метод для прореживания по каналам (например, по фильтрам в свёрточных нейросетях).

-
- ▶ Работа представлена на Всероссийской научной конференции МФТИ.
 - ▶ Статья подготовлена к публикации и планируется подача в рецензируемый журнал.